



Facultad de Ciencias

UNAM

ANÁLISIS MULTIVARIADO

Práctica 2

MULTICOLINEALIDAD, COMPONENTES PRINCIPALES, NORMAL
MULTIVARIADO, PROPORCIÓN DE VARIANZAS, BILOT Y REGRESIÓN
LINEAL MÚLTIPLE.

Enríquez Hernández Leobardo

14 de junio de 2024

Índice

1. Análisis exploratorio de datos.	1
2. Determinar si existe multicolinealidad usando VIF o KMO.	8
3. Componentes principales	9
4. Distribucion Normal multivariado.	10
5. Diagrama de Dispersion y proporción de varianza.	11
6. Biplot, agrupaciones y variables importantes.	12
7. Regresión lineal múltiple. Modelo predictivo.	17

Utilizando la base de datos Student-Scores y con las columnas de las calificaciones obtenidas por los alumnos realizaremos algunos análisis de multicolinealidad de covariables, componentes principales, pruebas de distribución normal multivariado, diagrama de dispersión y proporción de varianza, el Biplot y agrupaciones, verificación de variables importantes, y regresión lineal múltiple.

1. Análisis exploratorio de datos.

Antes de comenzar cargamos la base de datos que vamos a utilizar y hacemos una inspección rápida del tipo de datos para cada variable y de la estadística descriptiva de los datos numéricos.

```
#Cargamos la base de datos
student_scores <- read.csv("DataSets/student-scores.csv")
summary(student_scores) #Estadística descriptiva de los datos numéricos
```

```
##      id      first_name      last_name      email
##  Min.   : 1.0  Length:2000    Length:2000    Length:2000
##  1st Qu.: 500.8 Class :character  Class :character  Class :character
##  Median :1000.5 Mode  :character  Mode  :character  Mode  :character
##  Mean   :1000.5
##  3rd Qu.:1500.2
##  Max.   :2000.0
##      gender      part_time_job      absence_days
##  Length:2000    Length:2000      Min.   : 0.000
##  Class :character  Class :character  1st Qu.: 2.000
##  Mode  :character  Mode  :character  Median  : 3.000
##                           Mean   : 3.666
##                           3rd Qu.: 5.000
##                           Max.   :10.000
##      extracurricular_activities weekly_self_study_hours career_aspiration
##  Length:2000              Min.   : 0.00      Length:2000
##  Class :character          1st Qu.: 5.00      Class :character
##  Mode  :character          Median :18.00      Mode  :character
##                           Mean   :17.76
##                           3rd Qu.:28.00
##                           Max.   :50.00
##      math_score      history_score      physics_score      chemistry_score
##  Min.   :40.00      Min.   :50.00      Min.   :50.00      Min.   : 50
##  1st Qu.:77.00      1st Qu.:69.75      1st Qu.:71.00      1st Qu.: 69
##  Median :87.00      Median :82.00      Median :83.00      Median : 81
##  Mean   :83.45      Mean   :80.33      Mean   :81.34      Mean   : 80
##  3rd Qu.:93.00      3rd Qu.:91.00      3rd Qu.:92.00      3rd Qu.: 91
##  Max.   :100.00      Max.   :100.00      Max.   :100.00      Max.   :100
##      biology_score     english_score     geography_score
##  Min.   :30.00      Min.   :50.00      Min.   :60.00
##  1st Qu.:69.00      1st Qu.:72.00      1st Qu.:71.00
```

```

## Median : 81.00  Median :83.00  Median : 81.00
## Mean   : 79.58  Mean    :81.28  Mean   : 80.89
## 3rd Qu.: 91.00  3rd Qu.:91.00  3rd Qu.: 91.00
## Max.   :100.00  Max.    :99.00  Max.   :100.00

```

Luego clasificaremos estas variables por escalas, agruparemos las numéricas y enteros por un lado, luego las nominales y ordinales por otro lado.

```

tipoDatos <- sapply(student_scores, class) # Saber los tipos de datos
continuas <- which(tipoDatos == "numeric") # continuas
enteras <- which(tipoDatos == "integer") # enteras
numericas <- c(continuas,enteras) #unirlas

nominales <- which( tipoDatos == "factor") # categoricas
ordinales <- which( sapply(student_scores, is.ordered) ) # ordinales
categoricas <- c(nominales, ordinales) #unirlas

```

Ya que realizamos una inspección básica a las columnas de la base de datos, el tipo de dato, así como sus estadísticos principales lo que sigue será definir otras 2 variables donde tomaremos las columnas de las calificaciones de los alumnos y otra con la variable dependiente para hacer el modelo de regresión.

```

vars_predict <- c('math_score','history_score','physics_score',"chemistry_score",
                  "biology_score","english_score","geography_score") #covariables
dependiente <- "weekly_self_study_hours" #variable explicada o dependiente

```

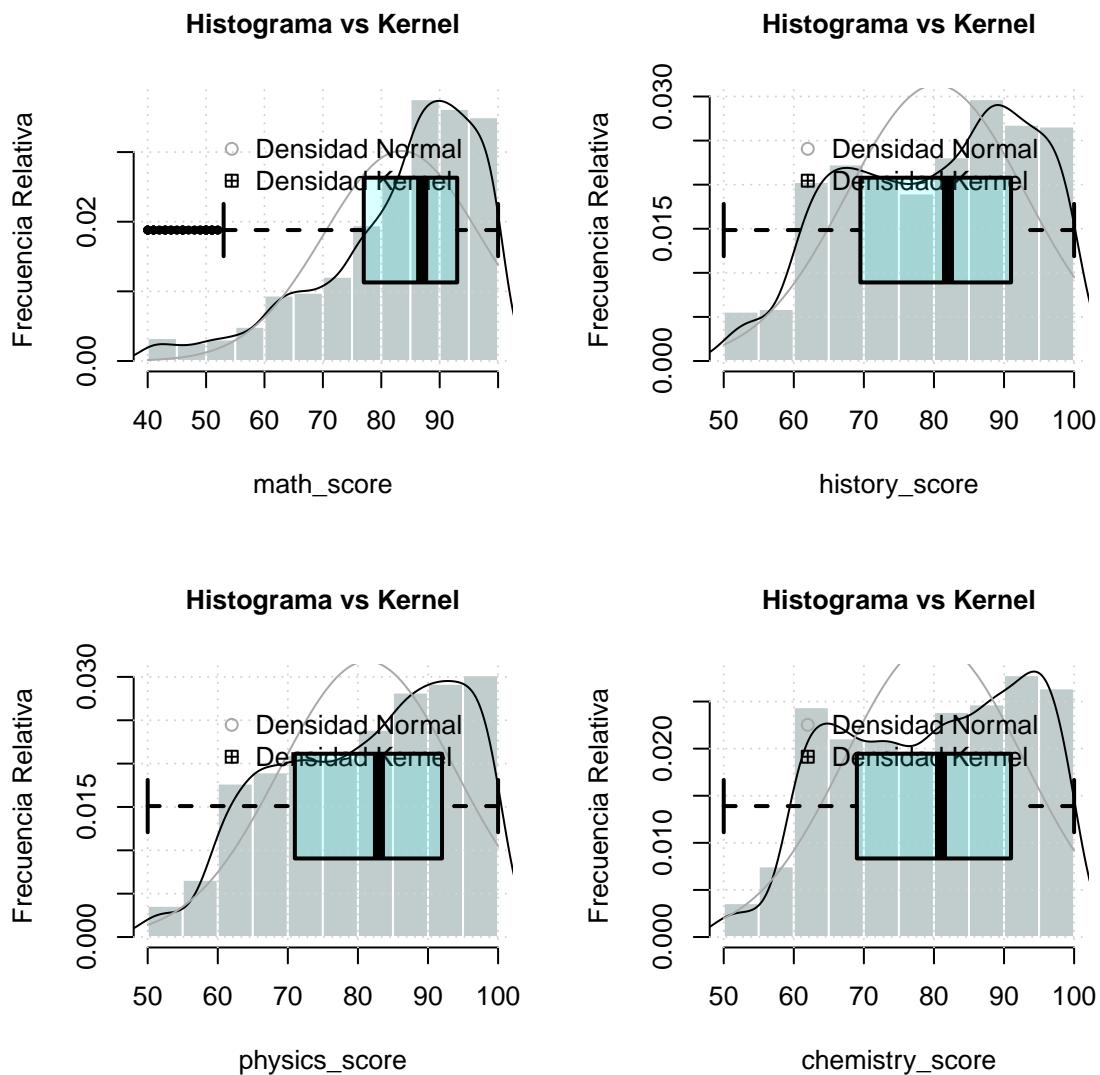
Con las nuevas variables definidas haremos un análisis exploratorio para ver si no tendremos problemas de escalas con los datos, outliers, NA's, etc. Algo que debemos mencionar es que con la variable vars_predict donde guardamos las calificaciones de los alumnos no tendremos problemas de escala ya que las calificaciones por alumno se encuentran definidas con el mismo rango escalar de 0 a 100.

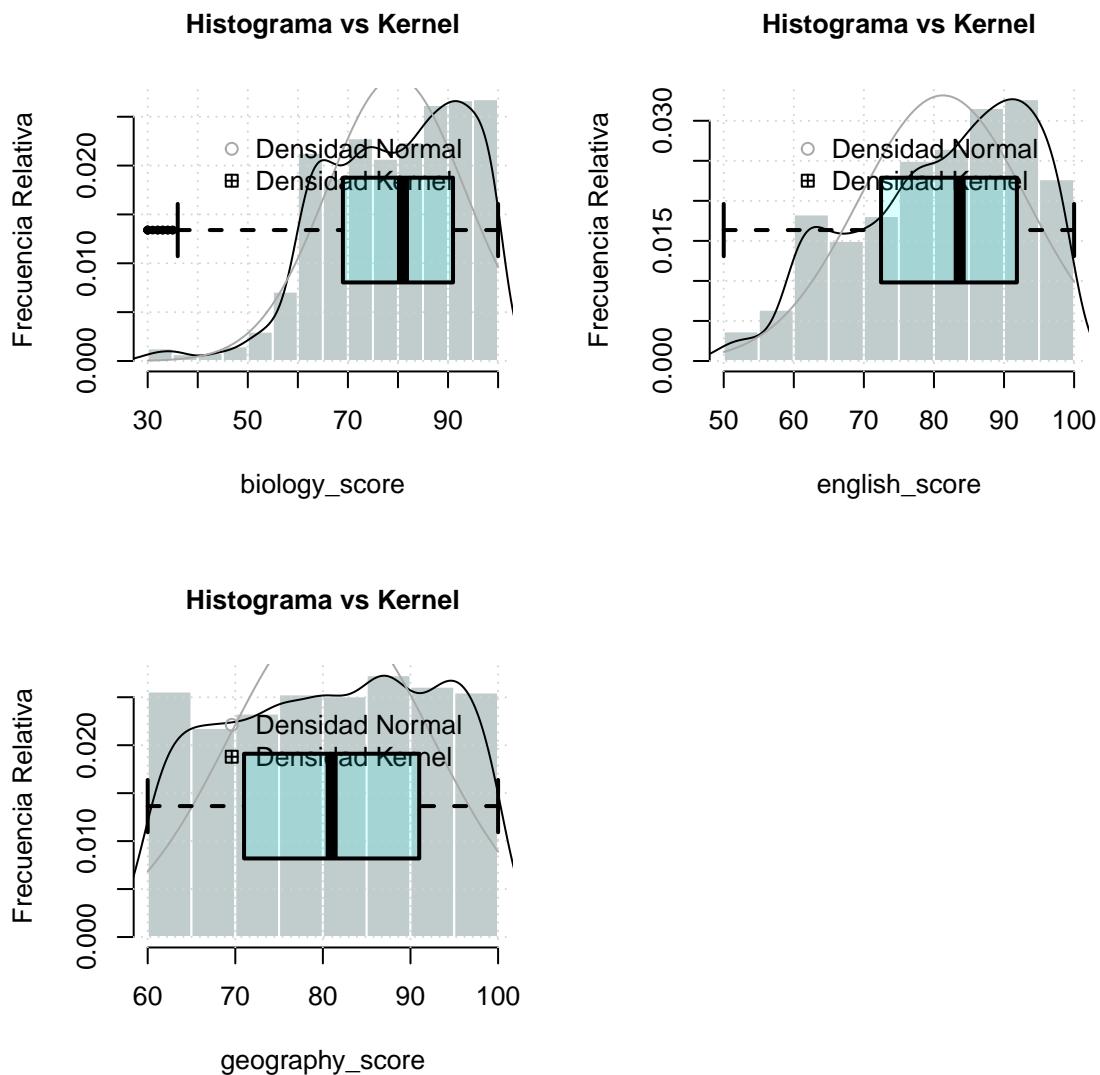
En los siguientes histogramas con BoxPlot y densidad combinados, podemos observar algunos comportamientos de las variables explicativas. Por ejemplo math_score tiene una asimetría hacia la izquierda (o negativa), mostrando varios outliers por debajo del primer cuantil. Por otro lado, geography_score muestra un comportamiento más uniforme, con mayor simetría y sin outliers.

```

par(mfrow = c(2, 2))
multi.hist(student_scores[, vars_predict]) # Histogramas con formato de funciones.R

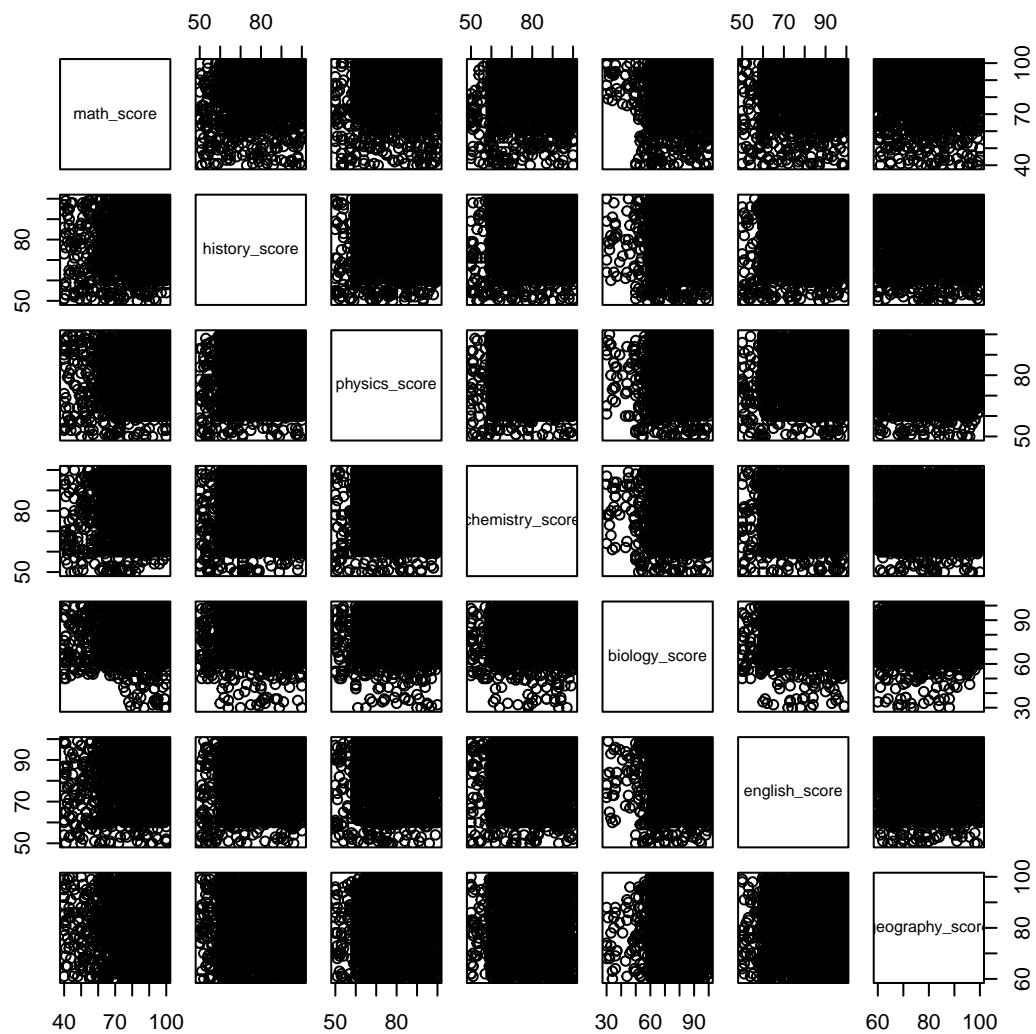
```





En las siguientes gráficas de dispersión entre las covariables, podemos observar que no hay relaciones lineales evidentes entre éstas.

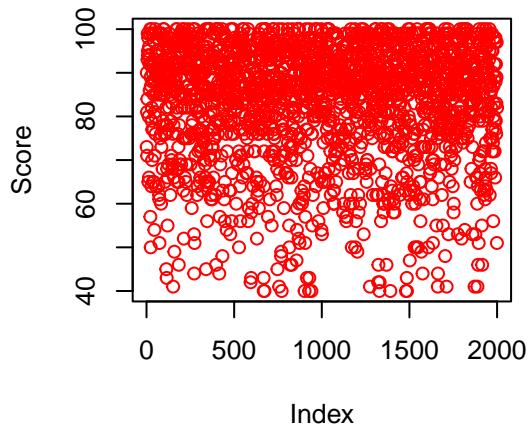
```
pairs(student_scores[,vars_predict])
```



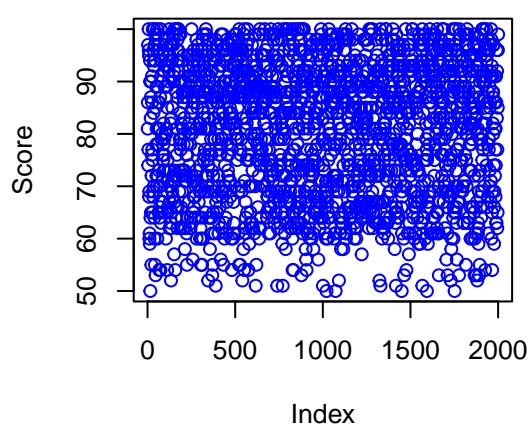
En las siguientes gráficas de dispersión individuales, no se muestra algún comportamiento, tendencia o patrón definido.

```
par(mfrow = c(2, 2))
plot(student_scores$math_score,col="red",main = "Calificaciones en Matematicas",ylab = "Score")
plot(student_scores$history_score,col="blue",main = "Calificaciones Historia",ylab = "Score")
plot(student_scores$physics_score,col="cyan",main = "Calificaciones Fisica",ylab = "Score")
plot(student_scores$chemistry_score,col="seagreen",main = "Calificaciones Quimica",ylab = "Score")
```

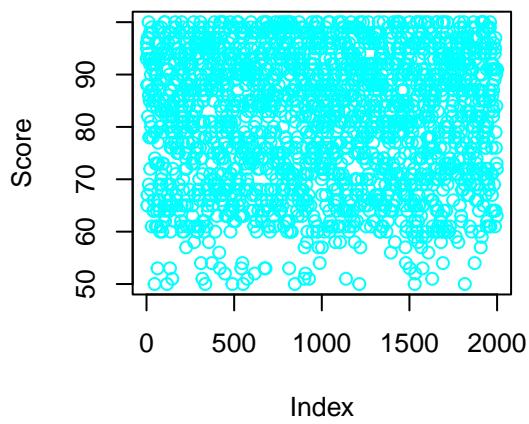
Calificaciones en Matematicas



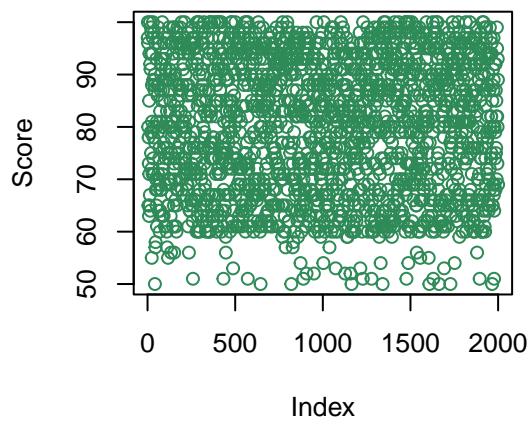
Calificaciones Historia



Calificaciones Fisica

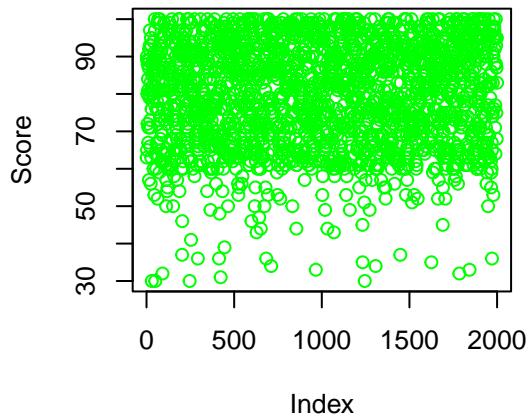


Calificaciones Quimica

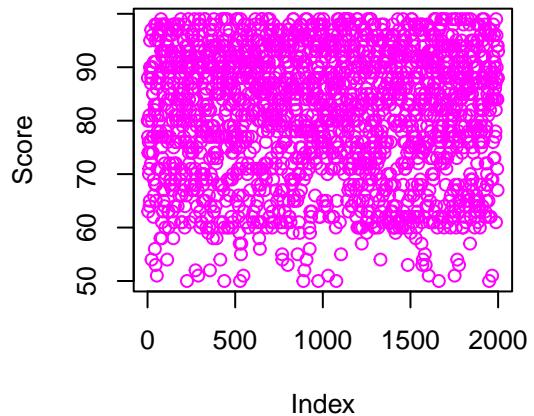


```
plot(student_scores$biology_score,col="green",main = "Calificaciones Biologia",ylab = "Score")
plot(student_scores$english_score,col="magenta",main = "Calificaciones Ingles",ylab = "Score")
plot(student_scores$geography_score,col="orange",main = "Calificaciones Geografia",ylab = "Score")
```

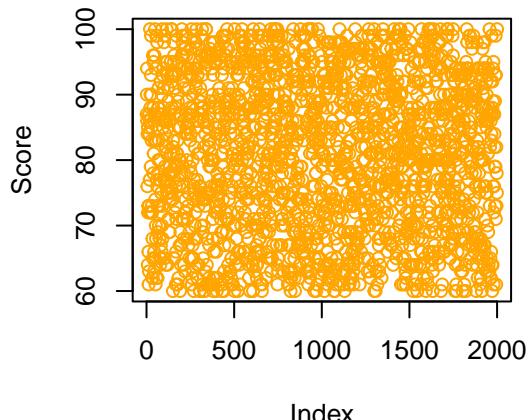
Calificaciones Biología



Calificaciones Ingles



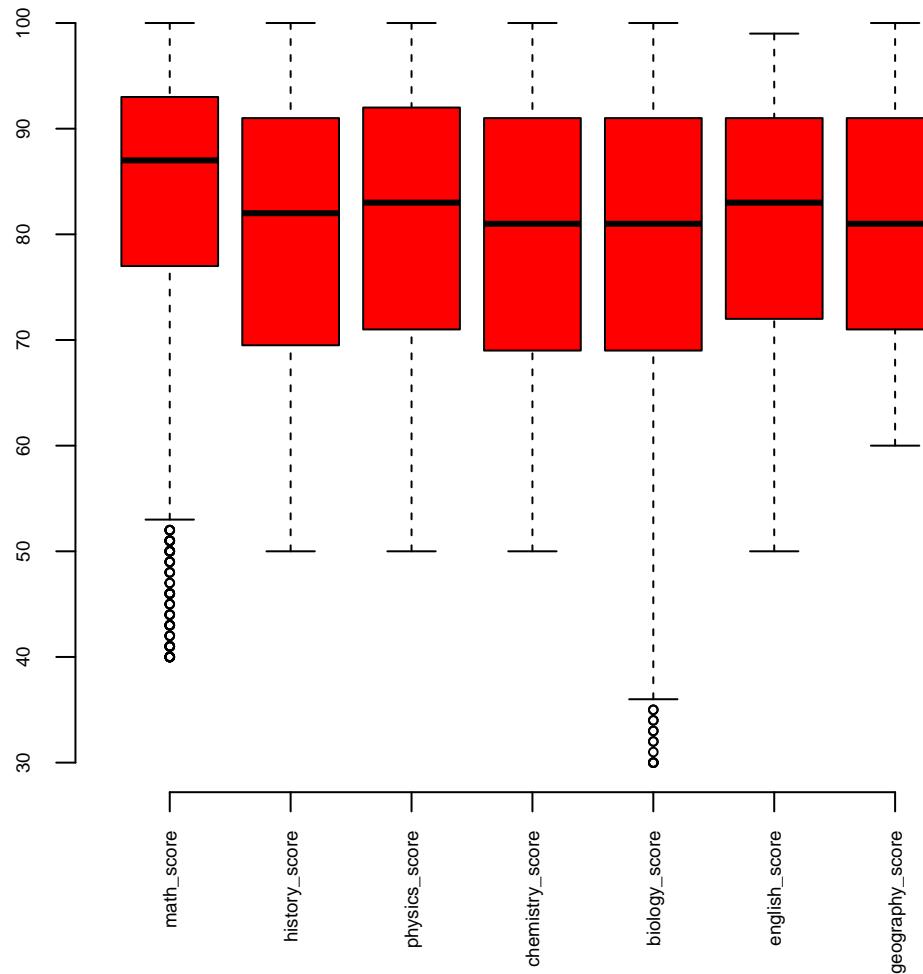
Calificaciones Geografia



En los siguientes BoxPlot parece no haber problemas de escala, y algunos outliers en las variables math_score y biology_score.

```
par(bty = "n")
boxplot(student_scores[,vars_predict],main = "Boxplot de variables predictoras",las = 3,cex=0.6,cex.main=1.5)
```

Boxplot de variables predictoras



Del análisis exploratorio que hicimos podemos ver que en efecto no tenemos problemas de escala con las calificaciones, tenemos algunos valores outliers o atípicos pero no es algo que nos genere problemas.

2. Determinar si existe multicolinealidad usando VIF o KMO.

```
KMO(student_scores[,vars_predict])

## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = student_scores[, vars_predict])
## Overall MSA =  0.66
## MSA for each item =
##      math_score   history_score   physics_score   chemistry_score   biology_score
##            0.66           0.65           0.65           0.67           0.67
##      english_score   geography_score
##            0.65           0.67
```

De los resultados obtenidos de la prueba KMO tenemos que los valores son mediocres o regulares para nuestras variables, pues están fuera del rango 0.8 a 1, donde la muestra sería adecuada para el análisis factorial. Sin

embargo no son menores a 0.6, que indicaría que la muestra no es adecuada.

Por otro lado, podemos observar el factor de inflación de varianza y parece no haber multicolinealidad entre las covariables.

```
# definimos los datos que usara el modelo
#variables originales
datos <- student_scores[c(vars_predict, dependiente)]
fit_model <- lm(weekly_self_study_hours ~., data = datos)
colinearidad <- data.frame(Variance_Inflation_Factor = vif(fit_model));colinearidad

##          Variance_Inflation_Factor
## math_score           1.059224
## history_score        1.055562
## physics_score        1.047626
## chemistry_score       1.051409
## biology_score         1.046167
## english_score         1.043667
## geography_score      1.027365
```

3. Componentes principales

Ahora obtendremos las componentes principales de nuestras variables predictoras. Se observa que la proporción de varianza no se acumula rápidamente a 1, el primer componente tiene 0.23, y los primeros tres acumulan 0.52, es decir, la mitad. Hasta el quinto componente acumula 77 %.

```
comps <- princomp(student_scores[,vars_predict])
summary(comps)

## Importance of components:
##                 Comp.1    Comp.2    Comp.3    Comp.4    Comp.5
## Standard deviation   16.1894537 13.2037936 12.3394732 12.0545319 11.7906155
## Proportion of Variance 0.2328853  0.1549084  0.1352916  0.1291155  0.1235238
## Cumulative Proportion 0.2328853  0.3877937  0.5230853  0.6522008  0.7757246
##                         Comp.6    Comp.7
## Standard deviation   11.3260534 11.1413200
## Proportion of Variance 0.1139816  0.1102938
## Cumulative Proportion 0.8897062  1.0000000
```

La matriz Gamma o de vectores propios es la siguiente.

```
##### loadings: Matriz Gamma
comps$loadings

##
## Loadings:
##             Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7
## math_score     0.455  0.490  0.218  0.547  0.404      0.207
## history_score  0.380  0.368 -0.500 -0.330 -0.207  0.563
## physics_score  0.348 -0.195  0.589  0.137 -0.509  0.332 -0.327
## chemistry_score 0.401           0.368 -0.727  0.320 -0.268
## biology_score   0.489 -0.712 -0.362  0.180  0.293
## english_score    0.285  0.250 -0.299  0.107 -0.327 -0.644 -0.484
## geography_score  0.217 -0.127           -0.490 -0.291  0.782
##
##             Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7
## SS loadings    1.000  1.000  1.000  1.000  1.000  1.000  1.000
```

```

## Proportion Var  0.143  0.143  0.143  0.143  0.143  0.143  0.143
## Cumulative Var  0.143  0.286  0.429  0.571  0.714  0.857  1.000

```

La muestra aleatoria de las componentes principales es la siguiente, se muestran las primeras 10.

```

#### scores: La muestra aleatoria de las ccomponentes ppales
head(comps$scores, 10)

```

```

##          Comp.1      Comp.2      Comp.3      Comp.4      Comp.5      Comp.6
## [1,] -0.7618592  3.9668266 16.9228253 -19.763332 -12.299268 -2.028698
## [2,] 27.2381257 -3.9896721  8.8395286 -8.133651 -3.200276 -3.822412
## [3,] 10.8878736 10.2934527 11.6784544 -19.563597 -15.583157  8.038332
## [4,] -5.2530396 -21.6573752  6.4468393 -4.023467 -0.870790  8.953877
## [5,] -15.6437646  0.3758993 -11.3431384  9.306846  9.325239  2.860983
## [6,]  2.6354894 19.3433696 -13.7773673 -3.262716  3.103894  6.729581
## [7,] 14.6028988  4.9981457  0.6833324 11.341741  5.301996 24.818274
## [8,]  4.0685963  4.0334681 -8.8920743 13.544673 -1.177618 19.489528
## [9,]  3.2070066 -3.4125735 19.3950023  7.330242  9.122398  3.460563
## [10,] -9.7758235  8.8484338 17.0498812 15.711055  5.489164  7.068756
##          Comp.7
## [1,]  0.3967555
## [2,]  0.0857024
## [3,]  8.8575581
## [4,]  7.2897149
## [5,]  4.9865151
## [6,] 10.9458277
## [7,] -12.4114245
## [8,] 11.1719512
## [9,] -5.9750084
## [10,] -0.1306289

```

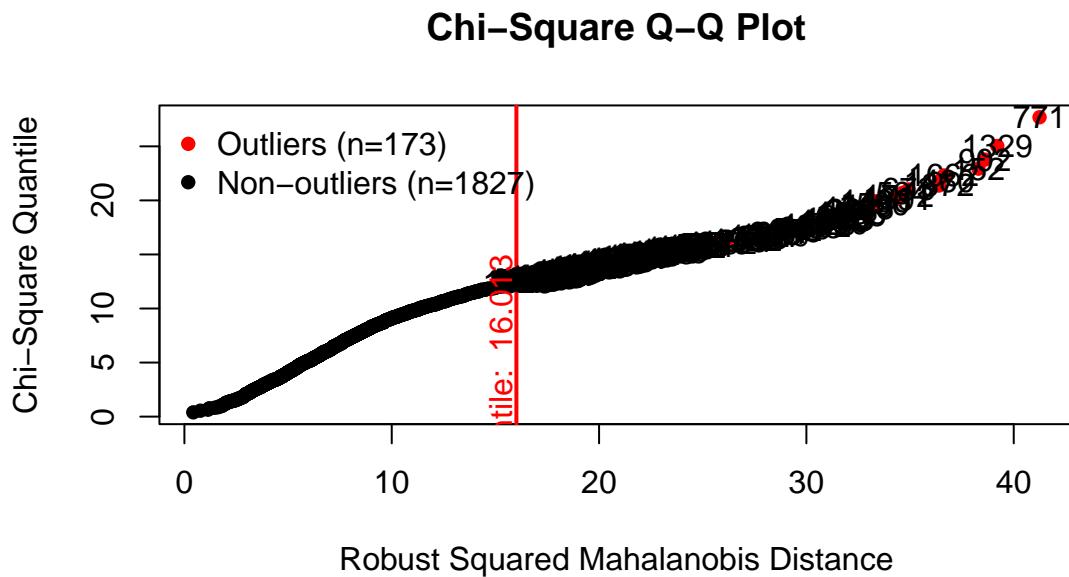
4. Distribucion Normal multivariado.

Con las componentes obtenidas veremos si estas se distribuyen de forma normal multivariada con el Henze-Zirkler's test y el método de detección de outliers quan que es un método cuantil basado en la distancia Mahalanobis. A continuación se muestra el Chi-Square Q-Q Plot generado.

```

#fit <- MVN::mvn(data = comps$scores, mvnTest = "hz", multivariateOutlierMethod = "quan")
scores_matrix<-as.matrix(comps$scores)
scores_matrix<-as.data.frame(scores_matrix)
names(scores_matrix)<-c("comp1", "comp2", "comp3", "comp4", "comp5", "comp6", "comp7" )
ajuste <- MVN::mvn(data = scores_matrix, mvnTest="hz", multivariateOutlierMethod="quan")

```



Observemos que el test de Henze-Zirkler rechaza que sea normal multivariado.

```
ajuste$multivariateNormality
```

```
##          Test      HZ p value MVN
## 1 Henze-Zirkler 3.050838     0  NO
```

Finalmente, el test de Anderson-Darling muestra que para 5 de los 7 componentes no forman una normal multivariada, particularmente las primeras dos componentes que nos interesan.

```
ajuste$univariateNormality
```

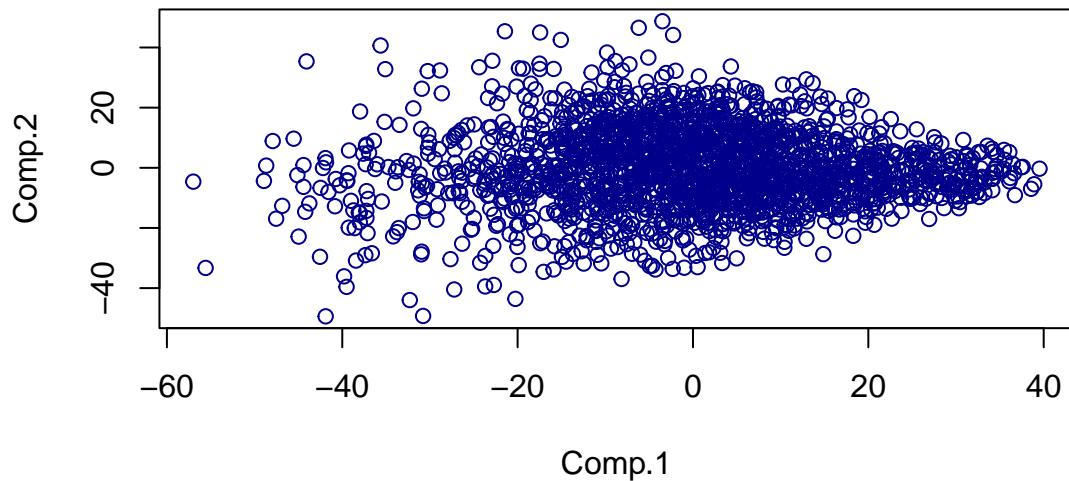
##	Test	Variable	Statistic	p value	Normality
## 1	Anderson-Darling	comp1	2.3329	<0.001	NO
## 2	Anderson-Darling	comp2	1.4887	8e-04	NO
## 3	Anderson-Darling	comp3	0.2034	0.8765	YES
## 4	Anderson-Darling	comp4	1.2723	0.0026	NO
## 5	Anderson-Darling	comp5	0.5219	0.184	YES
## 6	Anderson-Darling	comp6	1.1058	0.0067	NO
## 7	Anderson-Darling	comp7	0.8082	0.0365	NO

5. Diagrama de Dispersion y proporción de varianza.

Con la variable de scores obtenida del calculo de las componentes principales graficaremos un diagrama de dispersión tomando únicamente las primeras 2 componentes. Lo que podemos observar es que las primeras 2 componentes no están conservando mucha variabilidad de los datos originales.

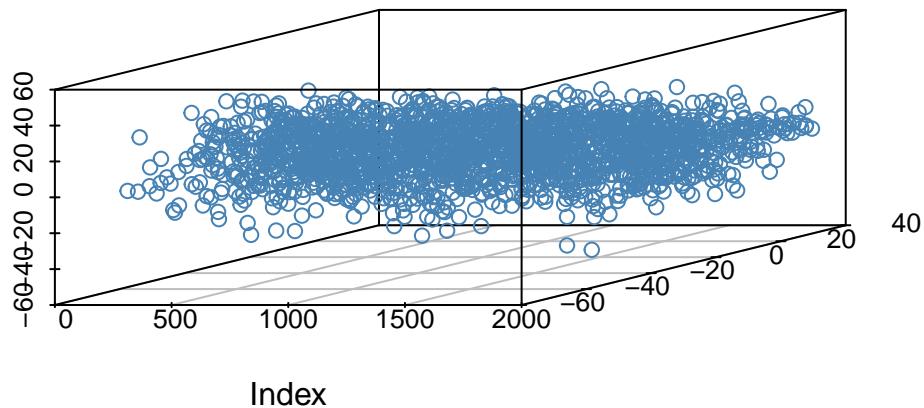
```
plot(comps$scores[,c(1,2)], col = "blue4", main = "Gráfico con 2 componentes")
```

Gráfico con 2 componentes



Si graficamos los primeros tres componentes tenemos lo siguiente.

```
scatterplot3d(comps$scores[,c(1,3)], color="steelblue")
```

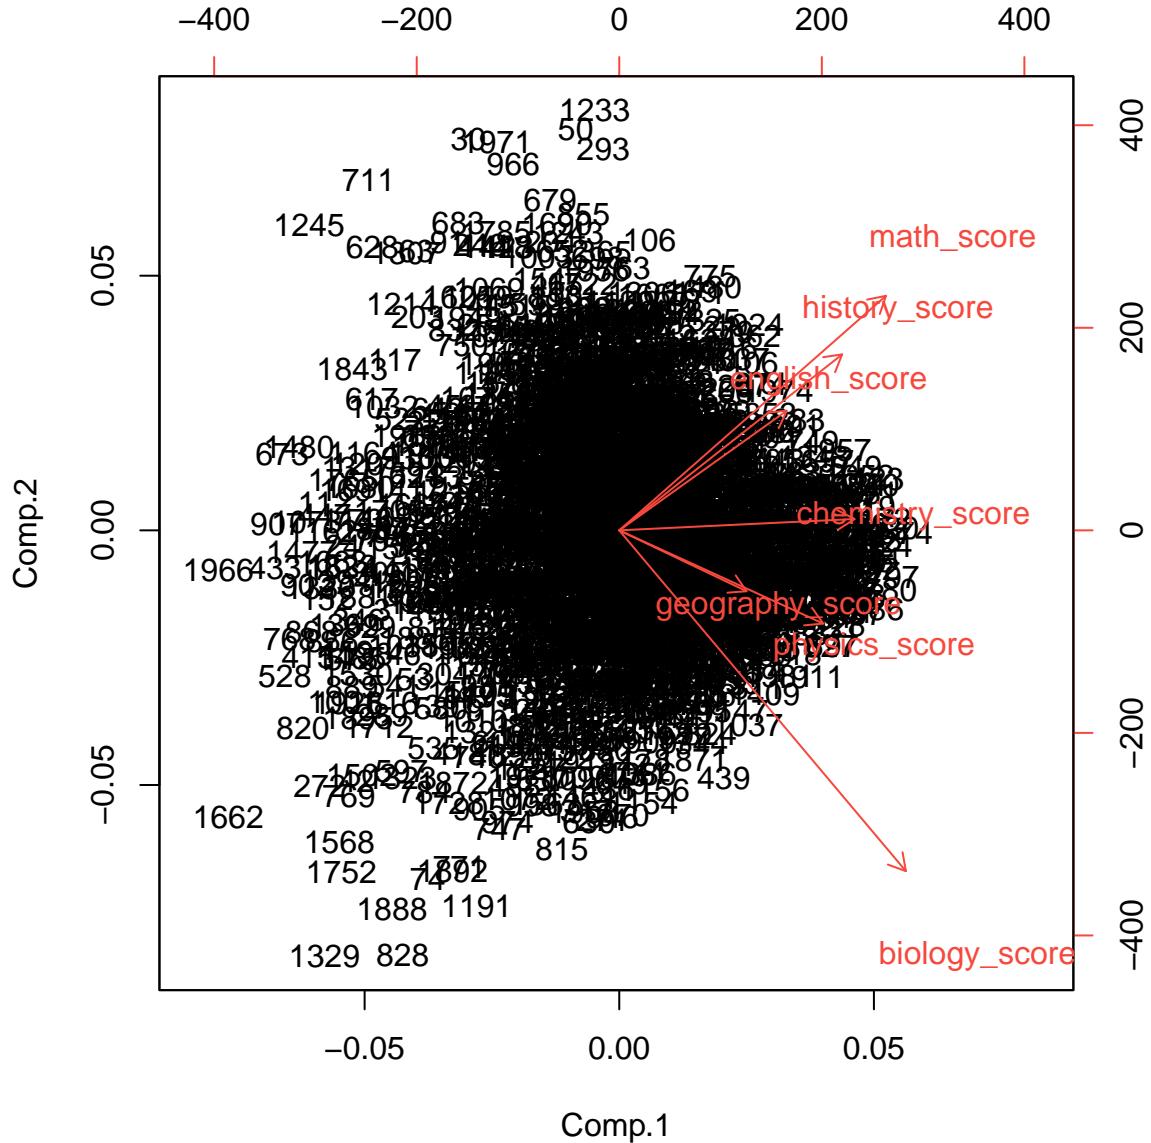


6. Biplot, agrupaciones y variables importantes.

En la siguiente gráfica Biplot de los primeros dos componentes vemos las flechas que son las variables y los puntos numéricos que son las observaciones. El largo de las flechas indica la varianza, entre más largas mayor varianza. El coseno del ángulo entre las flechas aproxima la correlación entre las variables, entre más cercano a 90 o 270 grados menor correlación entre las variables, un ángulo de 0 o de 180 grados refleja correlación de 1 y -1 respectivamente. Observamos aquí las correlaciones entre las variables dentro de los componentes

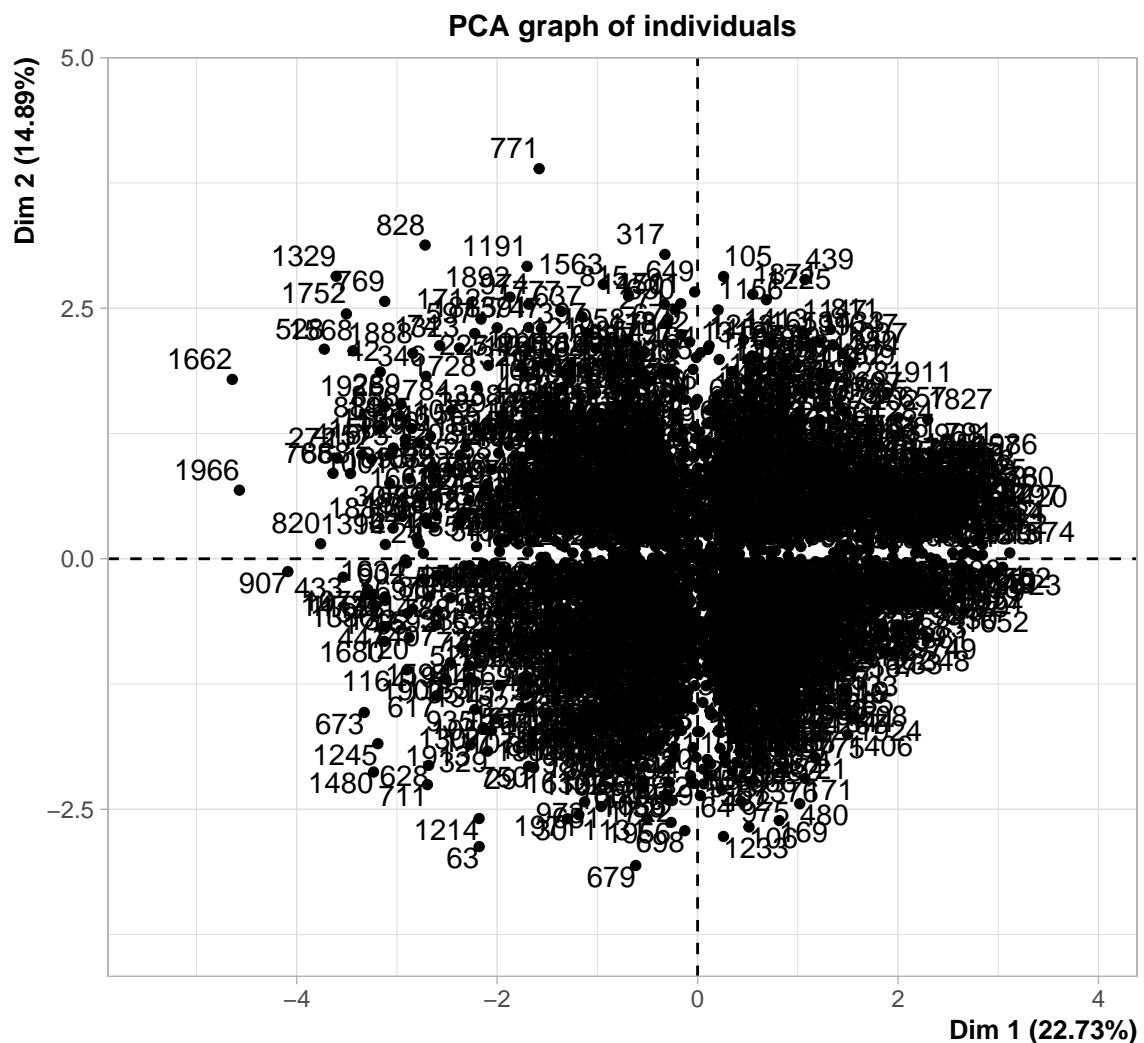
principales.

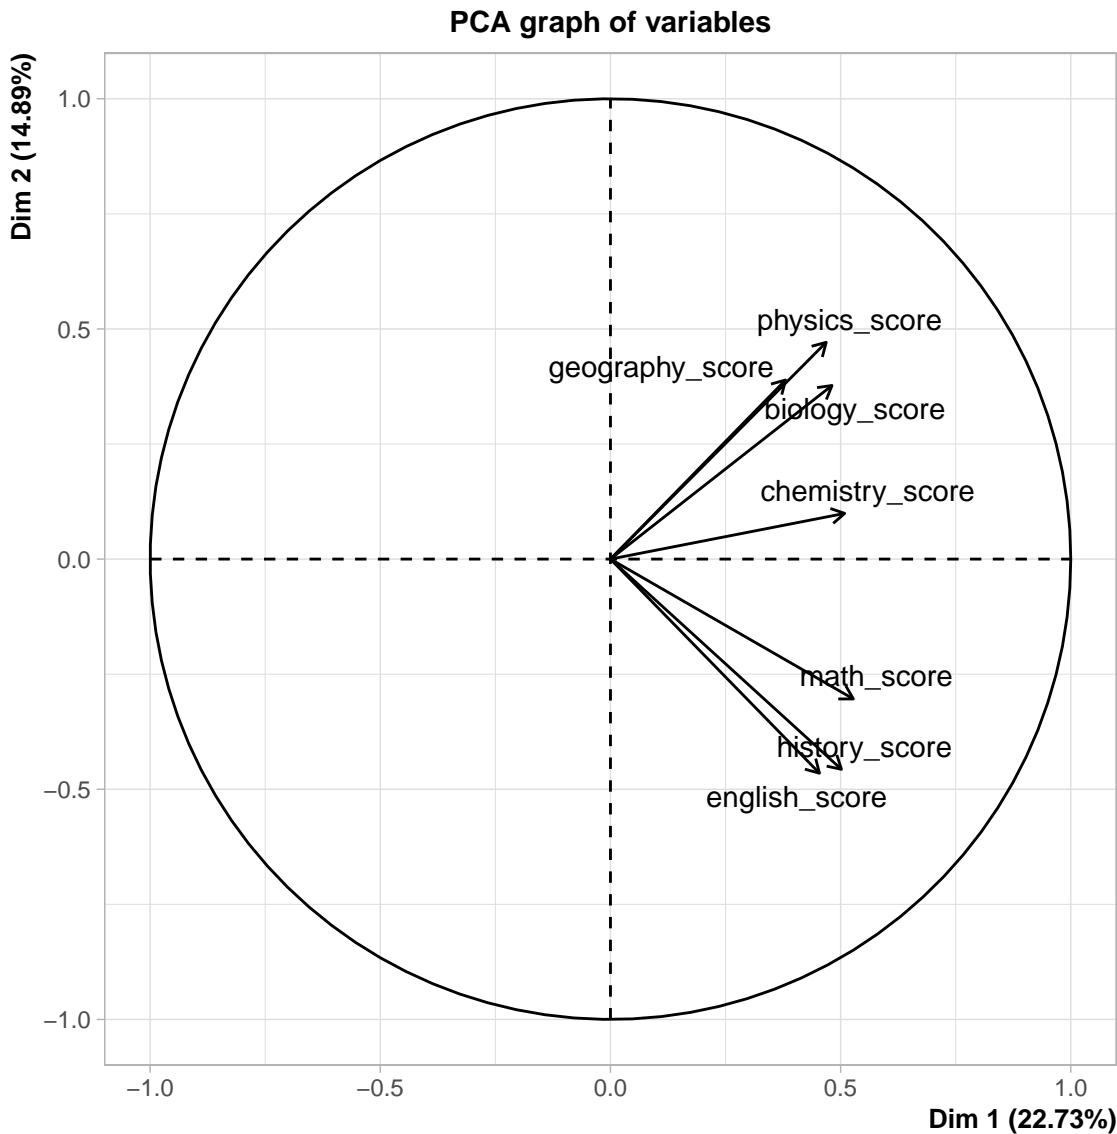
```
biplot(comps)
```



Por otro lado, podemos usar otro método, en el que en ncp indicamos el número de componentes principales que queremos, y con ello obtenemos un PCA graph, por una parte de observaciones y por otro de la variable, por separado.

```
par(mfrow = c(1, 2))
pca_comps <- PCA(student_scores[,vars_predict], scale.unit = T, ncp = 3, graph = T) #FactoMineR package
```

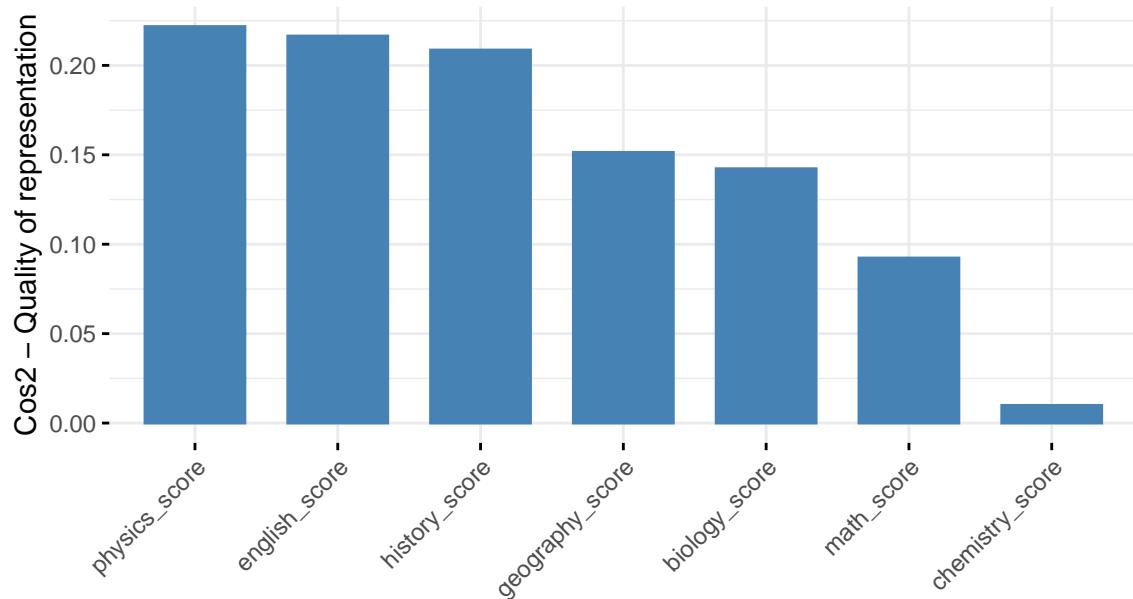




Para determinar la importancia de cada componente con las variables originales usaremos la función `cos2` la cual nos dice que un valor bajo significa que la variable no está perfectamente representada por esa componente, mientras que un valor alto significa que es una buena representación de esa variable con esa componente. Con Coseno 2 podemos observar la importancia de las variables en las primeras componentes principales. En este caso tenemos las correlaciones entre las variables y las componentes principales.

```
fviz_cos2(pca_comps, choice = "var", axes = 2) #factoextra package
```

Cos2 of variables to Dim–2



Observando las dimensiones tenemos lo siguiente.

```
pca_comps$desc <- dimdesc(pca_comps, axes = c(1,2), proba = 0.05)
pca_comps$desc$Dim.1
```

```
##
## Link between the variable and the continuous variables (R-square)
## =====
##          correlation      p.value
## math_score       0.5277368 7.999187e-144
## chemistry_score  0.5088131 3.603752e-132
## history_score    0.5017574 5.212873e-128
## biology_score    0.4812949 1.757672e-116
## physics_score    0.4687030 9.099105e-110
## english_score    0.4540056 2.806852e-102
## geography_score  0.3803661 7.369194e-70

pca_comps$desc$Dim.2

##
## Link between the variable and the continuous variables (R-square)
## =====
##          correlation      p.value
## physics_score    0.47086177 6.726618e-111
## geography_score   0.38903172 2.900618e-73
## biology_score     0.37711742 1.310961e-68
## chemistry_score   0.09926032 8.696948e-06
## math_score        -0.30379176 5.706193e-44
## history_score     -0.45669936 1.267281e-103
## english_score     -0.46520160 5.978037e-108
```

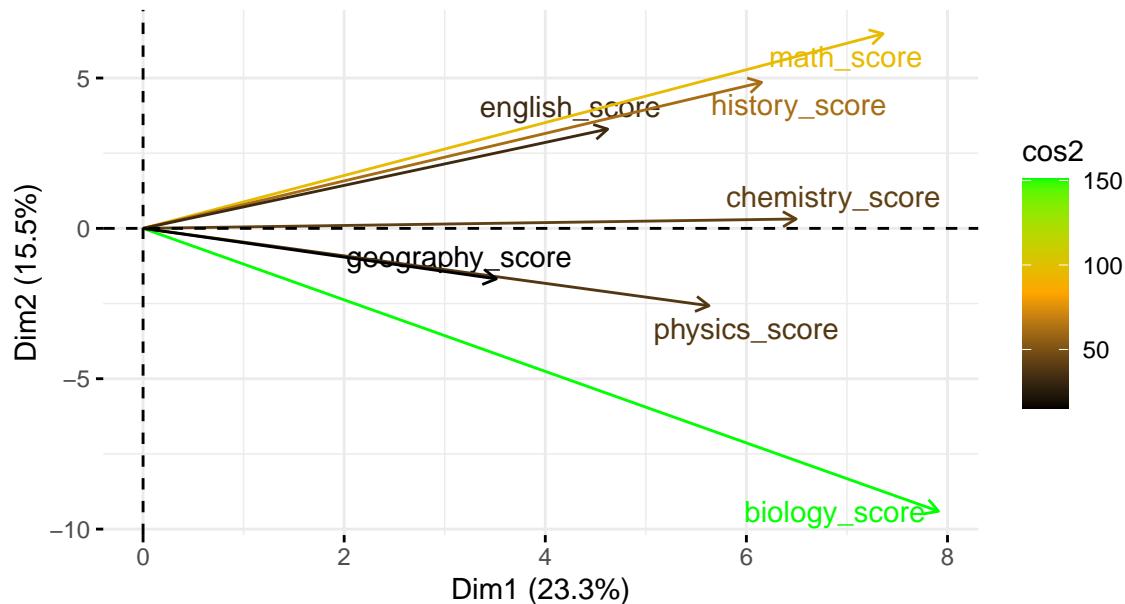
Otra forma de visualizar esto es combinar el biplot y la importancia de las componentes en el que los atributos con puntuaciones cos2 similares tendrán colores similares.

```

fviz_pca_var(comps, col.var = "cos2",      #replicar esta grafica con pca_comps en lugar
             #del parametro comps.
             gradient.cols = c("black", "orange", "green"),
             repel = TRUE)

```

Variables – PCA



7. Regresión lineal múltiple. Modelo predictivo.

Como ultimo paso ajustaremos un modelo de regresión usando las variables que definimos al principio donde tomamos las calificaciones y la variable que nos interesa modelar.

Se muestra a continuación el factor de inflación de varianza para un modelo de regresión con datos originales, todos son cercanos a 1 por lo que no parece haber problemas de multicolinealidad.

```

# definimos los datos que usara el modelo
#variables originales
datos <- student_scores[c(vars_predict, dependiente)]
fit_model <- lm(weekly_self_study_hours ~., data = datos)
colinealidad <- data.frame(Variance_Inflation_Factor = vif(fit_model));colinealidad

##          Variance_Inflation_Factor
## math_score           1.059224
## history_score        1.055562
## physics_score        1.047626
## chemistry_score       1.051409
## biology_score         1.046167
## english_score         1.043667
## geography_score       1.027365

```

A continuación se muestra el summary del modelo ajustado con los datos originales.

```
summary(fit_model)
```

```
##
## Call:
```

```

## lm(formula = weekly_self_study_hours ~ ., data = datos)
##
## Residuals:
##      Min      1Q   Median      3Q      Max
## -26.8797 -7.5630  0.3167  8.0106 24.8864
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -62.86002   3.12556 -20.112 < 2e-16 ***
## math_score    0.28307   0.01790  15.815 < 2e-16 ***
## history_score 0.16762   0.01855   9.034 < 2e-16 ***
## physics_score 0.11099   0.01877   5.912 3.96e-09 ***
## chemistry_score 0.09286   0.01846   5.031 5.32e-07 ***
## biology_score  0.09042   0.01714   5.274 1.48e-07 ***
## english_score  0.15483   0.01954   7.925 3.76e-15 ***
## geography_score 0.09015   0.02003   4.501 7.17e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.28 on 1992 degrees of freedom
## Multiple R-squared:  0.2838, Adjusted R-squared:  0.2813
## F-statistic: 112.8 on 7 and 1992 DF, p-value: < 2.2e-16

```

A continuación mostramos el factor de inflación de varianza para un modelo de regresión con componentes principales, todos son 1 por lo que no hay problemas de multicolinealidad.

```

#componentes principales
data2 <- cbind(student_scores[,dependiente],comps$scores)
colnames(data2) <- c('weekly_self_study_hours','comp1','comp2','comp3','comp4','comp5','comp6','comp7')
data2<-as.data.frame(data2)
fit_model2 <- lm(weekly_self_study_hours ~ ., data = data2)
colinealidad_check <- data.frame(Variance_Inflation_Factor = vif(fit_model2)); colinealidad_check

##          Variance_Inflation_Factor
## comp1                  1
## comp2                  1
## comp3                  1
## comp4                  1
## comp5                  1
## comp6                  1
## comp7                  1

```

A continuación se presenta el summary del modelo ajustando con los componentes principales.

```

summary(fit_model2)

##
## Call:
## lm(formula = weekly_self_study_hours ~ ., data = data2)
##
## Residuals:
##      Min      1Q   Median      3Q      Max
## -26.8797 -7.5630  0.3167  8.0106 24.8864
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)

```

```
## (Intercept) 17.755500  0.229940  77.218 < 2e-16 ***
## comp1        0.376119  0.014203  26.481 < 2e-16 ***
## comp2        0.143781  0.017415   8.256 2.70e-16 ***
## comp3       -0.001283  0.018635  -0.069   0.945
## comp4        0.081004  0.019075   4.247 2.27e-05 ***
## comp5       -0.015468  0.019502  -0.793   0.428
## comp6       -0.010707  0.020302  -0.527   0.598
## comp7        0.019595  0.020639   0.949   0.343
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.28 on 1992 degrees of freedom
## Multiple R-squared:  0.2838, Adjusted R-squared:  0.2813
## F-statistic: 112.8 on 7 and 1992 DF,  p-value: < 2.2e-16
```